



UNIVERSIDAD DE MÁLAGA



Máster en Ingeniería del Software e Inteligencia Artificial

Enfoques Modernos de Resolución de Entidades: Uso de
PLN y Modelos Basados en Grafos para la Integración de
Datos Financieros en el Banco Central Europeo

Modern Approaches to Entity Resolution: Leveraging NLP
and Graph-Based Models for Financial Data Integration at
the European Central Bank

Realizado por
Isidro Javier García Fernández

Tutorizado por
José Manuel Jerez Aragonés
Alessio Chiaramoni

Departamento
Lenguajes y Ciencias de la Computación
UNIVERSIDAD DE MÁLAGA

MÁLAGA, junio de 2026



UNIVERSIDAD
DE MÁLAGA



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA INFORMÁTICA

MÁSTER UNIVERSITARIO EN INGENIERÍA DEL SOFTWARE E
INTELIGENCIA ARTIFICIAL

**Enfoques Modernos de Resolución de Entidades: Uso de PLN y
Modelos Basados en Grafos para la Integración de Datos
Financieros en el Banco Central Europeo**

**Modern Approaches to Entity Resolution: Leveraging NLP and
Graph-Based Models for Financial Data Integration at the
European Central Bank**

Realizado por
Isidro Javier García Fernández

Tutorizado por
José Manuel Jerez Aragonés
Alessio Chiaramoni

Departamento
Lenguajes y Ciencias de la Computación

UNIVERSIDAD DE MÁLAGA
MÁLAGA, JUNIO DE 2026

Resumen

El objetivo de este Trabajo de Fin de Máster es aplicar técnicas de Resolución de Entidades basadas en Procesamiento del Lenguaje Natural sobre la base de datos RIAD (*Register of Institutions and Affiliates Data*) del Banco Central Europeo, con el propósito de desarrollar modelos predictivos para la detección de registros duplicados. Este proceso permite identificar de manera unívoca si distintos registros representan a la misma institución en el mundo real, superando las limitaciones de las herramientas de comparación de texto tradicionales. Estos modelos avanzados capturan el contexto semántico de los datos, mostrando similitudes ante errores tipográficos, acrónimos o variaciones corporativas internacionales. Se aplican técnicas para automatizar la agrupación de entidades, reducir la carga de verificación manual y garantizar la calidad de la información. Para obtener estos resultados, se utiliza un enfoque teórico-práctico donde se analizan diversas técnicas de filtrado, arquitecturas neuronales basadas en Cross-Encoders y teoría de grafos para determinar cuáles son las más apropiadas para extraer agrupaciones significativas y evaluar la calidad de los resultados obtenidos, así como su implementación en producción. Se han conseguido modelos que alcanzan métricas de recuperación y valor F1 de aproximadamente un 94 %, optimizando el espacio de búsqueda de forma eficiente.

Palabras clave: Resolución de Entidades, Procesamiento del Lenguaje Natural, Banco Central Europeo

Abstract

The objective of this Master's Thesis is to apply Entity Resolution techniques based on Natural Language Processing to the European Central Bank's RIAD (Register of Institutions and Affiliates Data) database, with the aim of developing predictive models for the detection of duplicate records. This process enables us to uniquely identify whether different records represent the same real-world institution, overcoming the limitations of traditional text comparison tools. These advanced models capture the semantic context of the data, revealing similarities despite typographical errors, acronyms, or international corporate variations. Techniques are applied to automate entity clustering, reduce the manual verification workload, and ensure data quality. To achieve these results, a theoretical-practical approach is employed, involving the analysis of several blocking techniques, neural architectures based on Cross-Encoders, and graph theory to determine the most appropriate methods for extracting meaningful clusters, evaluating the quality of the obtained results, and their implementation in a production environment. The resulting models achieved recall and F1-score metrics of approximately 94 %, efficiently optimizing the search space.

Keywords: Entity Resolution, Natural Language Processing, European Central Bank

Índice

1. Introducción	7
1.1. Motivación	7
1.2. Objetivos	8
1.3. Metodología	9
1.4. Tecnologías usadas	10
2. Preliminares	13
2.1. El problema de Resolución de Entidades	13
2.2. Métricas Clásicas de Similitud Léxica	14
2.3. Representaciones Vectoriales de Cadenas de Texto	15
2.4. Métodos de similitud semántica	16
2.4.1. Bi-Encoders y Cross-Encoders	17
2.4.2. Búsqueda Aproximada de Vecinos Más Cercanos con FAISS	19
2.5. El Sistema Actual de Resolución de Entidades en RIAD	20
2.6. Métricas de Evaluación	22
3. Comprensión y Preparación de los datos	25
3.1. Comprensión del problema	25
3.2. Comprensión de los datos	25
3.3. Preparación y descripción de los datos	26
4. Modelado y Evaluación	31
4.1. Blocking	31
4.1.1. Vectorización mediante n-gramas de caracteres y TF-IDF	33
4.1.2. Vectorización TF-IDF con tokenización sub-palabra	33
4.1.3. Filtrado Híbrido: similitud coseno y Jaro-Winkler	34
4.1.4. Bloqueo semántico: Bi-Encoder y FAISS	35
4.2. Matching	36
4.3. Refinamiento mediante Grafos Topológicos	37

4.4. Evaluación de los resultados	39
5. Conclusiones y Líneas Futuras	45
5.1. Conclusiones	45
5.2. Líneas Futuras	46

Introducción

1.1. Motivación

La arquitectura del sistema financiero global ha experimentado una gran transformación en las últimas dos décadas, impulsada por la necesidad de monitorizar y estabilizar el sistema financiero. Tras la crisis financiera mundial de 2008, instituciones reguladoras como el Banco Central Europeo (BCE) identificaron la necesidad de rastrear con precisión las exposiciones cruzadas y la interconexión real entre las contrapartes internacionales.

Para dotar a las autoridades de una visión completa del riesgo, el BCE impulsó grandes infraestructuras de datos como el marco AnaCredit, que exige la identificación unívoca de las entidades para calcular la exposición crediticia total de un grupo corporativo. Sin embargo, la viabilidad de estos sistemas de análisis financiero depende absolutamente de la calidad de los datos de referencia, almacenados en RIAD (Register of Institutions and Affiliates Data), repositorio central del Sistema Europeo de Bancos Centrales con más de 16 millones de contrapartes internacionales [1].

Mantener la calidad de los datos y la integridad referencial evitando duplicados en una base de datos de esta importancia es un gran reto técnico. Para alcanzar una representación unificada y consolidada de cada institución es necesario resolver el problema conocido como Resolución de Entidades (*Entity Resolution*) o Vinculación de Registros (*Record Linkage*).

El interés principal de este Trabajo de Fin de Máster (TFM) surge de las limitaciones del sistema actual de resolución de entidades presentes en RIAD. Dicho sistema se fundamenta en algoritmos tradicionales de similitud léxica y reglas deterministas. Aunque son métodos computacionalmente eficientes, carecen de comprensión semántica y como resultado, fallan sistemáticamente ante casos ambiguos (por ejemplo, no pueden distinguir “Ferrari S.p.A” como fabricante de coches de “Ferrari F.Lli Lunelli” como productor de vinos) o ante variaciones

corporativas (como “HP” y “Hewlett-Packard”). Es por ello que estos métodos sufren tasas de falsos positivos muy reducidas, exigiendo una carga inasumible de verificación manual.

En el contexto del BCE, la presencia de duplicados o fusión incorrecta de distintos grupos corporativos puede provocar un cálculo erróneo de la exposición al riesgo de un grupo corporativo, afectando directamente a la supervisión y a la estabilidad financiera.

En consecuencia, resulta necesario superar las limitaciones de la simple comparación de texto y transitar hacia arquitecturas neuronales más modernas. El empleo de modelos basados en transformadores combinados con análisis de topología de grafos ha demostrado ser una técnica de vanguardia para resolver este tipo de problemas, permitiendo capturar el contexto semántico de las entidades a analizar [2–4]. De esta manera, se posibilita una agrupación de entidades mucho más precisa, reduciendo la intervención manual y alineando la calidad de los datos de RIAD con las exigencias regulatorias actuales, todo ello operando bajo los rigurosos estándares de privacidad del BCE.

1.2. Objetivos

Este Trabajo de Fin de Máster surge como respuesta a la necesidad de las divisiones analíticas del Eurosistema por modernizar la gestión de entidades manteniendo la calidad de los datos. El objetivo principal de este proyecto es diseñar, implementar y evaluar una herramienta fundamentada en modelos neuronales de Aprendizaje Profundo para la detección sistemática de registros corporativos duplicados en la base de datos RIAD. Podemos desglosar el objetivo principal en varias etapas con objetivos específicos:

1. Construir un conjunto de datos equilibrado de evaluaciones de pares de entidades candidatas para entrenar el modelo.
2. Definir y evaluar métodos eficientes para la generación de candidatos que permitan reducir el inmenso volumen de la base poblacional a un espacio de búsqueda computacionalmente viable, sin comprometer la detección de verdaderos duplicados.
3. Implementar arquitecturas avanzadas de Procesamiento del Lenguaje Natural capaces de interpretar el contexto semántico y las particularidades del dominio legal para distinguir entre entidades distintas y registros duplicados.

4. Aplicar técnicas basadas en teoría de grafos para la detección y corrección de falsos duplicados en distintos grupos corporativos.
5. Evaluar empíricamente la mejora aportada por el sistema neuronal propuesto contrastándolo con el algoritmo determinista actual, evaluando tanto la calidad de las predicciones como la eficiencia computacional de la solución.

1.3. Metodología

Con el propósito de alcanzar estos objetivos, las tareas que se van a llevar a cabo se organizarán siguiendo la metodología CRISP-DM [5] (*Cross-Industry Standard Process for Data Mining*), que es una metodología ampliamente reconocida en el campo de la minería de datos. CRISP-DM representa el ciclo de vida de un proceso de minería de datos y se divide en seis fases principales:

- **FASE 1: Comprensión del problema.** Comprender al detalle qué es lo que se quiere conseguir realmente. El objetivo es descubrir desde el principio factores importantes que pueden influir en el resultado del proyecto. Se debe registrar la información que se conoce sobre la situación al comienzo del proyecto, así como los criterios de éxito y utilidad del resultado.
- **FASE 2: Comprensión de los datos.** En esta etapa se recopilan los datos para su posterior estudio, se exploran para comprender su comportamiento y se verifica su calidad (presencia de datos faltantes, errores en datos o metadatos, inconsistencias y similares), documentando hallazgos que guiarán las decisiones en el proyecto de minería de datos.
- **FASE 3: Preparación de los datos.** Se basa en el tratamiento inicial o preprocesamiento de los datos recopilados. Se seleccionan y limpian y, si es necesario, se construyen nuevos datos a partir de ellos.
- **FASE 4: Modelado.** Se eligen las metodologías de extracción de modelos, lo que puede incluir el ajuste de parámetros para optimizar el rendimiento o la propuesta e implementación de algoritmos innovadores para la obtención de los mismos. Utilizando estas metodologías, se generan los modelos, se comparan los resultados y se identifican aquellos que satisfacen los estándares mínimos establecidos por los expertos.

- **FASE 5: Evaluación.** Se evalúa la factibilidad de los modelos obtenidos, llevando a cabo un proceso de análisis crítico y sugiriendo mejoras para futuras iteraciones.
- **FASE 6: Uso y difusión:** Implementación de los modelos en el entorno de producción, asegurando que funcionen correctamente y generen valor de negocio. También incluye la preparación de documentos que recojan los avances conseguidos y permitan su difusión.

En la Figura 1 se visualizan las etapas de esta metodología.




Figura 1: Esquema de la metodología CRISP-DM. Elaboración propia basada en el esquema original [5]

Las fases de esta metodología se realizarán en orden secuencial en este documento. El primer capítulo de esta memoria, la introducción, se corresponde con la fase inicial de la metodología CRISP-DM, donde se analiza el problema y se establecen los objetivos. La última etapa de esta metodología, la fase de despliegue, se corresponde con la redacción de esta memoria, donde se detalla todo el estudio realizado, y la implementación de esta nueva herramienta para su uso en el equipo de RIAD de la Dirección General de Estadística del Banco Central Europeo. Por último, se incluye la sección de conclusiones y líneas futuras, donde se proponen vías de desarrollo que quedan abiertas para un estudio más detallado.

1.4. Tecnologías usadas

Se han empleado diversas tecnologías y herramientas para cada etapa del proyecto, abarcando desde la extracción de los datos hasta el entrenamiento e inferencia de los modelos neuronales. Principalmente se ha hecho uso de los lenguajes de programación Python y SQL.

El lenguaje SQL se ha utilizado mediante el motor de consultas Impala, para la extracción directa y manipulación inicial de los registros desde la base de datos institucional del Banco

Central Europeo. Específicamente, el proyecto se ha desarrollado sobre el entorno DEVO (*DISC Evolution*), la actual plataforma analítica basada en la nube del BCE orientada a la gobernanza y análisis de grandes volúmenes de datos [6]. Por su parte, Python (en su versión 3.12) ha sido el lenguaje vehicular de todo el proceso analítico. Se ha utilizado para el preprocesado y análisis exploratorio de los datos haciendo uso de librerías como Scikit-learn para la vectorización de cadenas de texto. Asimismo, se han utilizado *frameworks* especializados en aprendizaje profundo como PyTorch para la creación y evaluación de los modelos, así como las bibliotecas Transformers y Sentence-Transformers de Hugging Face [7].

Para el desarrollo, la experimentación y la visualización del proceso se ha utilizado el entorno corporativo Cloudera AI Workbench, trabajando principalmente mediante la interfaz de Jupyter Notebooks. Se determinó que una GPU NVIDIA T4 (16 GiB VRAM) proporcionaba el equilibrio óptimo entre latencia de inferencia y coste operativo. No obstante, se asignó 29 GiB de memoria RAM y 6 vCPU para asegurar la estabilidad del sistema durante el cálculo de operaciones.

Preliminares

En este capítulo se establecen las bases teóricas y los conceptos fundamentales necesarios para comprender la problemática de la Resolución de Entidades y las tecnologías empleadas en la solución propuesta.

2.1. El problema de Resolución de Entidades

La Resolución de Entidades es el proceso de identificar y fusionar registros duplicados (como personas, empresas o productos) dentro de una o varias bases de datos. En la literatura, es común encontrar términos similares para abordar este problema, como vinculación de registros (*Record Linkage*) o deduplicación de datos [8]. Es importante diferenciar este enfoque de la simple búsqueda de texto o coincidencia exacta de cadenas, ya que la diferenciación de entidades puede depender de otros atributos como identificadores únicos. El desafío consiste en encontrar estas coincidencias de manera eficiente y efectiva, lidiando con valores faltantes, errores tipográficos, uso de acrónimos y variaciones estructurales complejas. Existe una amplia variedad de aplicaciones, como la consolidación de historiales médicos de pacientes, la unificación de perfiles de clientes en sistemas de comercio electrónico y, en el caso de este estudio, la detección de interconexiones corporativas para el control de riesgos y la supervisión en el sector financiero.

El objetivo de la detección de duplicados se sostiene sobre tres pilares fundamentales de la calidad de los datos: la completitud (asegurando que la información sobre una entidad sea exhaustiva), la consistencia (garantizando que los valores registrados estén libres de contradicciones) y, fundamentalmente, la unicidad (confirmando que no existan duplicados de una misma entidad en el sistema).

El problema de Resolución de Entidades sobre grandes volúmenes de datos también tiene una gran limitación: la complejidad computacional. Comparar exhaustivamente todos los

registros entre sí para encontrar duplicados implica una complejidad cuadrática $O(n^2)$, completamente inviable en grandes bases de datos. Por esta razón, la literatura moderna divide el problema en un *pipeline* basado en dos fases: una fase inicial de filtrado o *blocking* con el objetivo de reducir el espacio de búsqueda, generando únicamente pares potencialmente similares, y una segunda fase de evaluación más precisa. De esta forma, los métodos de clasificación más costosos solo se aplican sobre un subconjunto reducido de candidatos.

En este estudio, el objetivo es descubrir y agrupar registros corporativos duplicados presentes en la base de datos RIAD del Banco Central Europeo. En este contexto, se desarrollarán diversos algoritmos y técnicas, evolucionando desde enfoques deterministas basados en reglas estáticas y métricas de similitud léxica hasta métodos mucho más avanzados basados en aprendizaje profundo y procesamiento de lenguaje natural.

2.2. Métricas Clásicas de Similitud Léxica

Tradicionalmente, la comparación de cadenas de texto se ha apoyado en reglas heurísticas y métricas que evalúan la similitud sintáctica, es decir, el parecido estructural de las cadenas de texto:

- Distancia de Damerau-Levenshtein o distancia de edición: establece el costo mínimo de operaciones singulares (inserciones, eliminaciones o sustituciones) necesarias para transformar una cadena de texto en otra. Aunque es eficaz frente a errores tipográficos, penaliza la variación de longitud de las palabras y es ineficiente en cadenas de texto complejas debido a su extrema sensibilidad al orden de los términos [9]. Se realiza construyendo una matriz donde, dadas dos cadenas de texto a y b , cada celda $d_{a,b}(i, j)$ representa la distancia mínima recursiva, es decir, el mínimo entre condiciones lógicas de inserción, eliminación, sustitución o transposición:

$$d_{a,b}(i, j) = \min \begin{cases} 0 & \text{si } i = j = 0 \\ d_{a,b}(i - 1, j) + 1 & \text{si } i > 0 \\ d_{a,b}(i, j - 1) + 1 & \text{si } j > 0 \\ d_{a,b}(i - 1, j - 1) + 1_{(a_i \neq b_j)} & \text{si } i, j > 0 \\ d_{a,b}(i - 2, j - 2) + 1_{(a_i \neq b_j)} & \text{si } i, j > 1 \text{ y } a_i = b_{j-1} \text{ y } a_{i-1} = b_j \end{cases}$$

Donde a_i representa el i -ésimo caracter de la cadena a , b_j el j -ésimo caracter de b y $1_{(a_i \neq b_j)}$ la función característica.

- Distancia de Jaro-Winkler: la similitud básica de Jaro, sim_j , entre dos cadenas s_1 y s_2 se define como:

$$sim_j = \begin{cases} 0 & \text{si } m = 0 \\ \frac{1}{3} \left(\frac{m}{|s_1|} + \frac{m}{|s_2|} + \frac{m-t}{m} \right) & \text{si } m > 0 \end{cases}$$

Donde m representa el número de caracteres coincidentes, $|s_i|$ es la longitud de la cadena, y t es el número de transposiciones necesarias para alinear los caracteres emparejados dividido por dos. Dos caracteres de s_1 y s_2 se consideran coincidentes si se encuentran dentro de una distancia máxima permitida (típicamente $\lfloor \frac{\max(|s_1|, |s_2|)}{2} \rfloor - 1$). La modificación de Winkler favorece aquellas cadenas que comparten un prefijo común, asumiendo que los errores tipográficos ocurren con menor frecuencia al inicio de una palabra [10]. Se introduce un factor de escala p (habitualmente 0,1) para la longitud del prefijo común l (concediendo un máximo de 4 caracteres). La distancia de Jaro-Winkler resulta ser su inverso:

$$sim_w = sim_j + l \cdot p \cdot (1 - sim_j)$$

$$d_{jw} = 1 - sim_w$$

- Distancia de Jaccard: es una métrica estadística proveniente de la teoría de conjuntos. Las cadenas de texto A y B se fragmentan utilizando técnicas de tokenización (separación por palabras) o mediante la extracción de n -gramas (subcadenas superpuestas de longitud n). Al operar sobre conjuntos sin un orden estricto, esta métrica destaca por tolerar la permutación de los términos [11].

$$d_J(A, B) = 1 - J(A, B) = 1 - \frac{|A \cap B|}{|A \cup B|} = \frac{|A \cup B| - |A \cap B|}{|A \cup B|}$$

2.3. Representaciones Vectoriales de Cadenas de Texto

Para poder realizar mejores comparaciones frente al desorden sintáctico es necesario abandonar la secuencia estricta de caracteres y transformar el texto en conjuntos de *tokens* o *n*-gramas. De este modo, cada cadena de texto se vectoriza en función del vocabulario del corpus,

generando matrices dispersas útiles para detectar elementos en común. Sin embargo, evaluar únicamente la intersección de estos tokens asume que todos los fragmentos tienen el mismo valor para identificar una entidad. A gran escala, esto supone un problema al emparejar entidades corporativas. Términos genéricos como “Corporation”, “Bank” o “S.A.” aparecen con demasiada frecuencia, lo que puede inflar artificialmente la similitud entre empresas completamente distintas. Para solucionar este problema, se recurre a representaciones que ponderan la rareza estadística de cada término.

En este contexto, la técnica TF-IDF (*Term Frequency - Inverse Document Frequency*) aborda la sobrerrepresentación de términos generales utilizando estadística, sustituyendo las limitaciones de los diccionarios estáticos de palabras vacías o *stopwords* [12]. Se dice que la relevancia de un token es directamente proporcional a su frecuencia de aparición en un texto específico, pero inversamente proporcional a su presencia global en el conjunto global. Su expresión formal establece:

$$TF\text{-}IDF(w, d) = TF(w, d) \cdot \log \left(\frac{|D|}{|\{d \in D : w \in d\}|} \right)$$

Donde $TF(w, d)$ cuenta las apariciones del token w en el registro d , $|D|$ representa el tamaño absoluto del corpus de entidades, y el denominador logarítmico indica el número de registros que contienen dicho token. De esta manera, las entidades se transforman en vectores numéricos dispersos donde los tokens más relevantes reciben un peso exponencial y los menos relevantes son matemáticamente suprimidos.

Una vez que las entidades han sido proyectadas en un espacio n -dimensional mediante los vectores u y v , la disimilitud entre dos registros se calcula algebraicamente evaluando el ángulo (θ) que forman sus vectores. La similitud coseno se define matemáticamente como el producto escalar de los vectores dividido por el producto de sus magnitudes:

$$\cos(\theta) = \frac{u \cdot v}{\|u\| \|v\|}$$

Esta técnica permite sustituir las comparaciones $\mathcal{O}(n^2)$ por algoritmos de búsqueda rápida en espacios vectoriales, facilitando una generación de candidatos escalable.

2.4. Métodos de similitud semántica

A pesar de la eficiencia computacional de los métodos mencionados anteriormente, estos algoritmos puramente estadísticos carecen de comprensión semántica para interpretar el tex-

to. Es por ello que es frecuente encontrar falsos positivos entre entidades que comparten un léxico pero en realidad pertenecen a dominios distintos, o bien falsos negativos ante variaciones donde no se comparten suficientes caracteres, como pueden ser traducciones transfronterizas o acrónimos.

Para solucionar este problema, el estado del arte ha transicionado hacia el uso de Modelos de Lenguaje pre-entrenados basados en la arquitectura *Transformer* (como BERT o Distil-BERT). Estos modelos tratan la variabilidad léxica y semántica a través de dos mecanismos fundamentales:

1. Tokenización en sub-palabras: Utilizan algoritmos como WordPiece [13] para dividir palabras desconocidas en fragmentos más pequeños y frecuentes. De este modo, se consigue prevenir el error de términos fuera del vocabulario o de errores tipográficos fusionando símbolos que maximizan la probabilidad de verosimilitud del lenguaje.
2. Representaciones contextualizadas: Mediante el mecanismo matemático de autoatención, calculan proyecciones vectoriales densas o *embeddings* donde el valor de cada fragmento está influenciado por el resto de la cadena. Esto permite que el modelo pueda capturar relaciones semánticas y comprender que el mismo término posee distintos significados dependiendo de los tokens cercanos.

De este modo, dos textos semánticamente similares producen vectores densos cercanos en el espacio multidimensional, independientemente de si comparten o no un mismo léxico.

2.4.1. Bi-Encoders y Cross-Encoders

Aplicar modelos semánticos a bases de datos a gran escala supone un reto de diseño importante. El obstáculo principal en la resolución de entidades en grandes bases de datos es su complejidad combinatoria, pues encontrar todos los duplicados en una base de datos de tamaño N requiere comparar cada registro con todos los demás. Esto implica una complejidad cuadrática $\mathcal{O}(N^2)$, un volumen de operaciones inasumible si se pretende aplicar un modelo complejo a tal volumen de combinaciones. Para resolver esta limitación, el Procesamiento del Lenguaje Natural plantea dos arquitecturas distintas para la comparación de pares de textos, cada una con un equilibrio diferente entre precisión de los resultados y escalabilidad. En la Figura 2 se muestran las diferencias arquitectónicas entre ambos enfoques:




Figura 2: Arquitectura de un modelo Bi-Encoder y Cross-Encoder.

- **Bi-Encoder:** diseñado para superar el cuello de botella computacional. Suelen estar implementados mediante redes siamesas (como *SentenceTransformers*), donde cada entidad se codifica de manera aislada a través de la red neuronal para generar su propio vector denso (*embedding*) [14]. Dado que el cálculo de la representación vectorial de un registro no depende de la interacción con el otro, los vectores de bases de datos masivas pueden precalcularse e indexarse en memoria. Sin embargo, esta ganancia en velocidad conlleva un coste analítico, pues los tokens de una entidad no interactúan con los de la otra a través de las capas de atención, lo que puede provocar que contradicciones pasen desapercibidas.
- **Cross-Encoder:** ambas cadenas de texto se concatenan y se introducen simultáneamente en el modelo *Transformer*. Esto permite que el mecanismo de atención evalúe interacciones cruzadas entre los tokens de ambas secuencias desde las primeras capas de la red. El vector salida correspondiente al *token* de clasificación global contiene las diferencias semánticas entre ambas secuencias a lo largo de varias capas y se transfiere a una capa de clasificación lineal (*feed-forward neural network*). Esta capa final aplica una función de activación sigmoide o *softmax* para dar como salida la probabilidad de que

los dos registros coincidan. Aunque esta arquitectura consigue una mayor precisión, su coste computacional es elevado, lo que los hace inviables para comparaciones directas de bases de datos a gran escala.

En la práctica, el estándar consiste en ejecutar *pipeline* en cascada donde la arquitectura Bi-Encoder se utiliza para la fase inicial de filtrado (*blocking* semántico), generando un subconjunto reducido de parejas candidatas, sobre los cuales se aplica el Cross-Encoder para una fase final de evaluación.

2.4.2. Búsqueda Aproximada de Vecinos Más Cercanos con FAISS

Aunque arquitecturas como Bi-Encoder puedan resolver la inferencia neuronal, el emparejamiento puede ser computacionalmente costoso si se dispone de una base de datos con millones de registros, pues encontrar las entidades más similares a una consulta nueva implicaría calcular la similitud coseno contra todos y cada uno de los vectores precalculados. Para que el filtrado de candidatos sea viable a gran escala, la literatura propone la Búsqueda Aproximada de Vecinos Más Cercanos. La lógica de estos algoritmos sacrifica la garantía de encontrar siempre el vecino matemáticamente exacto a cambio de una aceleración en el tiempo de respuesta. De este modo, se logra un equilibrio óptimo entre precisión y latencia.

En la actualidad, herramientas como FAISS (*Facebook AI Similarity Search*) representan el estado del arte en este dominio. FAISS permite indexar representaciones vectoriales densas (de Bi-Encoders) o dispersas (de TF-IDF) utilizando estructuras de datos avanzadas [15]. Dependiendo del volumen de los datos, suelen emplearse dos estrategias de indexación:

- Índices planos (*Flat Index*): se utilizan cuando el conjunto de datos tiene un tamaño moderado. En este caso, se realiza una búsqueda de fuerza bruta que busca un alto recall. Si los vectores de salida del modelo se normalizan previamente, el cálculo del producto escalar se vuelve equivalente a la similitud coseno, optimizando así las operaciones procesadas por el hardware (especialmente las GPU). El número total de regiones se escala estocásticamente en función de la población (N) mediante la heurística $4 \cdot \sqrt{N}$.
- Índice Cuantizado Invertido (*Inverted File Index*): es la solución para grandes poblaciones de datos. Se inspira en los motores de búsqueda textuales y divide el espacio vectorial en




Figura 3: Diagrama de Voronoi

múltiples regiones o clústeres (células de Voronoi) mediante algoritmos no supervisados como K-Means. Este enfoque requiere una fase de entrenamiento previo donde cada vector se asigna a su centroide maestro más cercano, almacenando su referencia en una estructura de datos denominada lista invertida. Al realizar una inferencia, el proceso se divide en dos etapas: una búsqueda gruesa para identificar los centroides más próximos a la consulta, y una búsqueda fina que calcula la distancia exacta únicamente contra los vectores de esas listas. El sistema utiliza el hiperparámetro de prospección (balance entre exploración y explotación) para determinar cuántas células adyacentes explorar, reduciendo la complejidad computacional a un tiempo de búsqueda sublineal.

2.5. El Sistema Actual de Resolución de Entidades en RIAD

El sistema actual de detección de duplicados empleado por el Banco Central Europeo en RIAD recae sobre la herramienta *Central Identification Service* (CIS) [1]. El ciclo de vida del proceso de Resolución de Entidades en el sistema actual se rige por un flujo de colas de entrada y salida y un motor central de emparejamiento. Cuando una entidad es registrada o sufre modificaciones en sus atributos relevantes, ingresa en la cola de entrada. A continuación, el sistema aplica una heurística de filtrado: la entidad extraída se compara de manera iterativa contra todas las entidades oficiales almacenadas en la base de datos que residan en su mismo país.

El algoritmo de evaluación, el cual determina si dos entidades son potenciales duplicados,

separa la información basándose en atributos clave y aplica métricas de similitud exactas o difusas según la naturaleza del dato. El grado de similitud final entre dos entidades se define mediante una fórmula de puntuación ponderada, que genera un valor acotado en el intervalo $[0, 1]$. Matemáticamente, la puntuación total (S_{total}) se expresa como la combinación lineal de las puntuaciones parciales de los atributos (s_i) por sus respectivos pesos (w_i) predefinidos en los metadatos del servicio:

$$S_{total} = (s_{name} \cdot w_{name}) + (s_{street} \cdot w_{street}) + (s_{city} \cdot w_{city}) + (s_{id} \cdot w_{id}) + (s_{zip} \cdot w_{zip})$$

De acuerdo con la configuración de metadatos actual (RIAD 4.0), la distribución de pesos estáticos asigna la mayor relevancia a los identificadores institucionales y al nombre de la entidad:

- Nombre de la Entidad (NM_ENTTY): $w_{name} = 0,45$ (difusa) .
- Identificadores (TYP_ENTTY_CD): $w_{id} = 0,40$ (exacta) .
- Calle ($STRT$): $w_{street} = 0,05$ (difusa).
- Ciudad (CTY): $w_{city} = 0,05$ (difusa) .
- Código Postal ($PSTL_CD$): $w_{zip} = 0,05$ (exacta) .

Antes de aplicar la evaluación métrica a los atributos textuales no estructurados (nombre, calle y ciudad), el sistema ejecuta una función de limpieza denominada CLEAN. Esta función elimina palabras consideradas “no importantes” o comúnmente llamadas *stopwords* (por ejemplo, para entidades residentes en Italia “Banca di Credito Cooperativo” se reduce a “Credito Cooperativo”) basándose en diccionarios estáticos dependientes del país de residencia y asumiendo que estas palabras no aportan entropía informativa para la diferenciación corporativa.

Para los atributos sujetos a comparación difusa, el sistema emplea la distancia de Jaro-Winkler (d_{jw}). No obstante, la puntuación parcial (s_{fuzzy}) devuelta por el sistema no es el valor bruto de la distancia, sino que se somete a una función de normalización y penalización que descarta directamente cualquier similitud por debajo de un umbral de 0,35. La expresión matemática utilizada es:

$$s_{fuzzy} = \frac{\max(d_{jw}(val_{entty1}, val_{entty2}) - 0,35, 0)}{0,65}$$

Por el contrario, para los atributos sujetos a comparación exacta (identificadores y códigos postales), la puntuación devuelta es estrictamente 1 si existe al menos una coincidencia exacta de valor entre los conjuntos de identificadores (independientemente de la clase o tipo de identificador registrado, mitigando así posibles errores de clasificación humana), y 0 en caso contrario.

Finalmente, el CIS genera candidatos en la cola de salida registrando las 10 entidades con mayor puntuación por encima de un umbral preestablecido, quedando a la espera de un análisis manual por parte de un analista experto.

2.6. Métricas de Evaluación

La Resolución de Entidades es un problema de clasificación binaria caracterizado por un desequilibrio de clases dado que la inmensa mayoría de las combinaciones posibles resultan en emparejamientos negativos reales, es decir, resultan ser entidades distintas. Dado este contexto, el rendimiento del *pipeline* propuesto se evalúa mediante métricas divididas en dos categorías según la fase del proceso: métricas de generación de candidatos y métricas de clasificación.

La Tasa de Reducción (*Reduction Ratio*, RR): mide cuánto se ha reducido el espacio de búsqueda de pares potenciales de entidades, evitando tener que comparar todos los registros entre sí, lo cual es computacionalmente costoso [8].

$$RR = 1 - \frac{|B|}{|A \times A|}$$

Donde $|B|$ es el volumen de pares candidatos generados por el *blocking*, y $|A \times A|$ es el cardinal del producto cartesiano de A consigo mismo, es decir, el número máximo teórico de pares posibles a comparar en la base de datos. Un valor de RR cercano a 1 indica que el sistema descartó casi todo el ruido existente.

La Completitud de Pares (*Pair Completeness*, PC): es el equivalente a la Recuperación (*Recall*). Evalúa la proporción de pares positivos reales que lograron superar el filtro en la generación de candidatos frente al total de positivos existentes en la base de datos.

$$PC = \frac{|B \cap M|}{|M|}$$

Donde M es el conjunto de duplicados verdaderos. En la etapa del *blocking* es preferible maximizar el PC , incluso si esto implica una ligera penalización en el RR para asegurar que el

clasificador final reciba a los candidatos correctos y no descarte coincidencias reales de forma prematura.

Considerando VP es el número de verdaderos positivos, VN es el número de verdaderos negativos, FP es el número de falsos positivos y FN es el número de falsos negativos que resultan al evaluar cada modelo, podemos establecer las métricas de la fase de *matching*.

La Precisión o tasa de acierto es la proporción de todas las clasificaciones positivas del modelo que son realmente positivas.

$$\text{Precisión} = \frac{VP}{VP + FP}$$

La Exhaustividad (*Recall*) mide la sensibilidad del modelo en la evaluación final de pares candidatos. Es la proporción de todos los positivos reales que se clasificaron correctamente como positivos.

$$\text{Exhaustividad} = \frac{VP}{VP + FN}$$

Por último, el Valor F1 (*F1-Score*) es la media armónica entre la Precisión y la Exhaustividad. Es conocida por ser una métrica de convergencia que penaliza fuertemente el desequilibrio entre ambas.

$$F_1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Exhaustividad}}{\text{Precisión} + \text{Exhaustividad}} = \frac{2 \cdot VP}{2 \cdot VP + FP + FN}$$

Cabe destacar que las métricas de precisión, recuperación y valor F_1 descritas evalúan el rendimiento del clasificador a nivel de pares de registros. No obstante, dado que el resultado final del *pipeline* es la formación de grupos de entidades duplicadas mediante la teoría de grafos, las métricas orientadas a evaluar la cohesión y la pureza de las componentes conexas se detallarán explícitamente en la Sección 4.3.

3

Comprensión y Preparación de los datos

En esta sección se englobarán las tres primeras fases de la metodología CRISP-DM: comprensión del problema, comprensión de los datos y preparación de los datos.

3.1. Comprensión del problema

En el capítulo introductorio de este documento se encuentra detallada la etapa de comprensión del problema. En los apartados 1.1 y 1.2 se describe el contexto y lo que se pretende conseguir, así como los criterios de éxito y utilidad del resultado. Se plantea como objetivo descubrir un modelo capaz de predecir si dos registros corporativos representan la misma entidad del mundo real. Se considerarán satisfechos los objetivos en el caso en el que se diseñe un sistema que logre clasificar dichos pares con un alto equilibrio entre exhaustividad y precisión, maximizando la detección de duplicados reales y reduciendo la intervención manual.

3.2. Comprensión de los datos

Este estudio se realiza paralelamente a las operaciones del equipo de RIAD de la Dirección General de Estadística del Banco Central Europeo. Se dispone de:

- **Conjunto de datos original (RIAD):** base de datos confidencial operada por el Banco Central Europeo y gestionado conjuntamente por todos los miembros del Sistema Europeo de Bancos Centrales bajo la titularidad del Comité de Estadística del SEBC con el objetivo de proporcionar el marco para los informes estadísticos sobre las instituciones

financieras en la Unión Europea [16]. Este conjunto de datos contiene información sobre alrededor de 16 millones de unidades organizativas individuales, así como diversos tipos de relaciones entre ellas. Cada registro de entidad está compuesto por atributos críticos para la identificación, tales como:

- **Nombre de la entidad.**
 - **Dirección física:** Incluye calle, ciudad y código postal.
 - **Identificadores institucionales:** Un conjunto de más de 180 tipos de códigos (como el *Legal Entity Identifier* (LEI), códigos fiscales o identificadores nacionales).
- **Conjunto de datos de validación:** Históricamente, los analistas expertos del equipo de RIAD en el BCE han validado las parejas candidatas emitidas por el algoritmo CIS de RIAD como tarea de aseguramiento de calidad de los datos. Estas evaluaciones se validan recurriendo a registros mercantiles, huellas digitales en internet o consultando plataformas institucionales. Se dispone de alrededor de 1.000 archivos en formato de hoja de cálculo elaborados mensualmente por analistas expertos desde el año 2021 con miles de pares candidatos ya evaluados. Para cada entidad se dispone de los mismos atributos mencionados anteriormente, junto con su código RIAD, fecha de registro y de cierre de la unidad organizativa. Cada registro incluye el dictamen manual de los expertos indicando si ambas entidades son duplicados o no.

3.3. Preparación y descripción de los datos

Como se ha descrito en la Sección 3, la base de datos RIAD cuenta con información sobre entidades tanto de la Unión Europea como extracomunitarias. Estas entidades pueden estar actualmente activas o bien liquidadas y terminada su actividad empresarial. Como el estudio se acota a las entidades activas residentes fuera de la Unión Europea, se construye un universo de aproximadamente 320.000 registros, distribuidos según la Figura 4.




Figura 4: Mapa de entidades activas en RIAD a 17 de Abril de 2026.

Cabe destacar la complejidad de los identificadores, pues existen 188 tipos distintos registrados en RIAD (e.g., LEI, códigos fiscales, identificadores nacionales). Dada la naturaleza descentralizada del sistema, que integra información proveniente de múltiples jurisdicciones e instituciones, es habitual que los datos presenten discrepancias de formato o variaciones en la estructura de las columnas. Por esta razón, en algunos casos estos identificadores no deben ser analizados como variables aisladas, sino como un conjunto no ordenado de palabras (*bag of words*) donde se estudie la relación cruzada entre distintos códigos.

Los atributos de interés extraídos para el posterior análisis de entidades son: código interno en RIAD, nombre de la entidad, dirección, código postal, ciudad, país, fecha de inicio y fin de actividad complementado con un vector concatenado de identificadores institucionales. Estos atributos son extraídos desde RIAD y son tratados aplicando distintas técnicas de *blocking* antes de pasar al modelo predictor. Nótese que a lo largo de este estudio sólo se detectarán duplicados entre entidades que compartan el mismo valor de país de residencia.

La preparación del conjunto de validación necesitó un preprocesamiento para transformar los datos en bruto de los ficheros de evaluación en secuencias estructuradas, aptas para ser introducidas por las arquitecturas de Procesamiento del Lenguaje Natural posteriormente. Para analizar toda esta información, se realizó inicialmente una transformación de los archivos

Excel originales a un formato intermedio JSONL donde se recogen todas las entidades procesadas. Tras su procesamiento se recogieron 116,749 pares candidatos de entidades, todos ellos únicos, correspondientes a un total de 83,236 entidades evaluadas. El conjunto presenta un claro desbalanceo de clases, con un 12,85 % de casos positivos y un 87,14 % de casos negativos. Entre los países con mayor representación en este grupo de candidatos destacan Estados Unidos (US) con 22,045 casos, de los cuales únicamente 2,693 fueron verdaderos duplicados (12 %) o Reino Unido (27,187), con 1,563 verdaderos positivos (6 %).

Para el entrenamiento de los modelos aplicados se solucionó el desbalanceo aplicando una técnica de filtrado basada en el descarte de pares negativos evidentes. Para ello, se eliminaron aquellas parejas que, según la evaluación preliminar, no resultaron corresponder a la misma entidad y que además, presentaron una puntuación dada por el CIS en RIAD inferior a un umbral de similitud de 0,7. De esta manera, se descartan las entidades sin apenas parecido léxico que resultaron no ser duplicados. Eliminar este ruido estadístico ayuda a los modelos de redes neuronales en su fase de entrenamiento, mejorando así su capacidad discriminativa.

Mediante esta estrategia se descartaron 63,370 pares candidatos negativos, reduciendo el conjunto de datos final a 53,379 parejas compuestas por 50,856 entidades distintas. Como resultado de este filtrado, se alcanzó una proporción de clases más ajustada: un 28,12 % de casos positivos frente a un 71,88 % de casos negativos. En la Figura 5 se observa el resultado de esta operación en la distribución del conjunto de datos de referencia.




Figura 5: Distribución de las clases en el conjunto de datos de referencia antes y después de aplicar el filtrado basado en el umbral de similitud del sistema CIS (distancia Jaro Winkler $< 0,7$).

Posteriormente se aplicó una división estratificada para mantener la distribución de clases en todas las particiones, separando en tres subconjuntos: entrenamiento (60 %) destinado al ajuste de los pesos de la red neuronal, validación (20 %) para para la monitorización en tiempo real y el ajuste de hiperparámetros, y un conjunto de prueba (20 %) reservado exclusivamente para la evaluación y extracción de métricas finales.

4

Modelado y Evaluación

Este capítulo abarca las dos siguientes etapas de la metodología CRISP-DM: Modelado y Evaluación e interpretación de los resultados. Se seleccionarán distintas técnicas de filtrado de parejas candidatas y la elección de un modelo para realizar la predicción final, seguidos de una comparación de los resultados según su metodología. En la sección 2 se han detallado diversos conceptos relacionados con los métodos que se utilizarán en este estudio.

Parte del código desarrollado y resultados obtenidos en esta sección pueden consultarse en un repositorio preparado para este Trabajo Fin de Máster [17].

En la Figura 6 se muestra el pipeline completo con todas las fases del proceso de Resolución de Entidades. Se comienza con una partición del conjunto de entidades extracomunitarias basada en el país de residencia, seguido por la fase de generación de candidatos o *blocking*. A continuación, se lleva a cabo la clasificación semántica par a par mediante la inferencia del modelo neuronal, y se concluye con un refinamiento topológico de componentes conexas mediante teoría de grafos para establecer unos grupos de entidades reales unificadas [20].

4.1. Blocking

El problema de la Resolución de Entidades en grandes bases de datos se fundamenta en la necesidad de evaluar exhaustivamente todos los registros, es decir, implicaría evaluar $\frac{n(n-1)}{2}$ permutaciones, lo cual resulta computacionalmente inviable. Para definir un espacio de búsqueda eficiente durante la fase de inferencia, es imperativo establecer una etapa de filtrado o *blocking* para la generación de candidatos. El propósito es dividir la población global en bloques disjuntos o interrelacionados de pares candidatos para la siguiente fase de predicción, evitando cálculos posteriores sobre pares potencialmente imposibles. En este estudio las en-




Figura 6: *Pipeline* propuesto para la Resolución de Entidades en RIAD [20].

tidades sólo podrán ser candidatas a emparejamiento si y solo si comparten el código de país de residencia.

Como el objetivo del estudio es detectar y predecir duplicados en la base de datos RIAD, es fundamental garantizar que los datos utilizados para el análisis sean representativos y capturen aquellas relaciones más evidentes de forma eficiente. Por ello se establece una primera fase de filtrado exacto en la que se recopilan todos los pares de entidades del subconjunto original que comparten al menos uno de los valores en sus identificadores institucionales, independientemente de la columna o tipología bajo la cual han sido registrados. Es claro que los registros que tienen identificadores en común deben ser evaluados, pues son potencialmente duplicados al referenciar posiblemente a la misma unidad organizativa. Como resultado de esta actividad, se extrajeron un total de 1,622 pares candidatos del conjunto de datos de RIAD. Dada la alta fiabilidad que implica compartir un identificador único, estas parejas eluden la fase de *blocking* general y avanzan directamente a la etapa de predicción. Sin embargo, no es común encontrar entidades que compartan un mismo identificador. Es por ello que el número de parejas candidatas encontradas no representan un gran porcentaje de la población. Por ello, y con el objetivo de agrupar el resto de unidades organizativas de RIAD, se aplican diversas técnicas de filtrado. El reto consiste en lograr la máxima cantidad de parejas garantizando que ningún duplicado verdadero quede excluido.

Durante la fase de experimentación se exploraron diversas estrategias de filtrado de candidatos. Para establecer una línea base de rendimiento computacional, se ejecutó un filtrado utilizando los algoritmos heredados del sistema actual. De entre las métricas de distancia léxi-

ca, se aplicó la similitud de Jaro-Winkler mediante funciones nativas de SQL. Se limitó la salida a un máximo de 10 entidades candidatas estableciendo un umbral de similitud de 0,85 sobre el nombre de cada registro. El proceso tomó 9 horas de cómputo ininterrumpido para detectar 480,000 candidatos a pesar de haber sido optimizado para descartar la redundancia simétrica. Sin embargo, este volumen de salida es excesivo para la posterior fase de emparejamiento en la que se emplean modelos semánticos de mayor coste computacional. Asimismo, el análisis cualitativo de estos resultados muestra una alta tasa de falsos positivos propia a las métricas puramente sintácticas. Por ejemplo, el algoritmo agrupó entidades como “BPOST HONG KONG LIMITED” y “TOYBE HONG KONG LIMITED” con una puntuación de 0,926 que, a pesar de compartir un relevante número de caracteres, representan instituciones financieras completamente distintas.

Con el objetivo de trasladar la carga de trabajo de SQL hacia un entorno más optimizado en Python, se aplicaron otras técnicas distintas de *blocking* basadas en la vectorización léxica y la búsqueda estructurada en espacios de alta dimensionalidad. De esta manera, se pretende ajustar la tolerancia de Jaro-Winkler frente a errores tipográficos reduciendo la complejidad computacional mediante operaciones de matrices dispersas. Para ello, se desarrollaron dos enfoques:

4.1.1. Vectorización mediante n-gramas de caracteres y TF-IDF

En una primera aproximación, los nombres de las entidades se fraccionaron en bloques de tres letras o trigramas respetando los límites de cada palabra. Para ello, se hizo uso de la librería *scikit-learn*). Se decidió conservar todos los tokens sub-palabra, incluso aquellos con una frecuencia mínima de una aparición, para no perder sensibilidad ante errores de escritura. Al aplicar la transformación TF-IDF sobre estos datos, se genera una matriz dispersa representando cada entidad en el espacio vectorial penalizando términos corporativos genéricos (como “Bank” o “Limited”) y enfocándose en los fragmentos que realmente hacen única a cada entidad.

4.1.2. Vectorización TF-IDF con tokenización sub-palabra

A pesar de la eficiencia computacional de subdividir cada nombre en n-gramas de caracteres, esta técnica no deja de ser una simple fragmentación de caracteres. Por ello, surge

la necesidad de integrar un tokenizador entrenado para dividir palabras raras, acrónimos o errores tipográficos en sub-palabras con significado estadístico. Se utilizó el modelo de lenguaje pre-entrenado DistilBERT (*distilbert-base-uncased*), el cual cuenta con un vocabulario de aproximadamente 30,500 tokens base [18]. Tras aplicar este tokenizador, las entidades se convierten en identificadores numéricos únicos y para optimizar el cálculo de similitudes, se evalúa mediante una matriz dispersa de filas penalizando aquellos tokens que aparecen con alta frecuencia en el corpus global (como los sufijos corporativos “bank”, “Ltd” o “llc”), otorgando mayor relevancia vectorial a las sub-palabras únicas que verdaderamente caracterizan a la entidad.

Se decidió utilizar DistilBERT como tokenizador léxico, en lugar de extraer sus *embeddings* con el objetivo de conseguir una eficiencia computacional, evitando procesar las secuencias a través de todas las capas de atención del modelo Transformer. Al utilizar únicamente su algoritmo de tokenización, el sistema es capaz de dividir palabras desconocidas, acrónimos o errores tipográficos en sub-palabras con significado estadístico, sin sufrir el coste de la inferencia neuronal.

Para reducir el espacio de búsqueda y evitar la comparación exhaustiva de todos los pares, la inferencia se optimizó de forma algebraica. Sobre la matriz TF-IDF resultante, se aplicó un modelo de búsqueda estructurada de los k -vecinos más cercanos. Mediante el cálculo iterativo de la Similitud del Coseno, el sistema extrae estrictamente los 10 registros más relevantes por entidad, descartando cualquier vínculo con una similitud inferior a un umbral establecido.

4.1.3. Filtrado Híbrido: similitud coseno y Jaro-Winkler

Como parte del análisis exploratorio, se valoró la opción de mantener un filtrado que utilice las métricas hasta ahora utilizadas en RIAD. Se decidió crear una metodología híbrida incluyendo un prefiltro donde los nombres de las entidades son procesados por el tokenizador de DistilBERT. Sin embargo, a diferencia del enfoque TF-IDF, se construye una matriz dispersa binaria donde únicamente se evalúa la presencia o ausencia de cada token, ignorando su frecuencia o peso estadístico global. Mediante el cálculo del producto escalar de los tensores normalizados (equivalente a la similitud coseno) se evalúan todos los registros con el objetivo de descartar de forma eficiente el ruido, es decir, eliminar aquellas parejas que definitivamente no representan duplicados reales. Al aplicar un umbral de similitud vectorial

moderado, se retiene una amplia cantidad de candidatos reduciendo considerablemente el espacio de búsqueda. Dado que este primer bloqueo opera con tolerancia al desorden de los tokens, el subconjunto extraído confía en la distancia de Jaro-Winkler para realizar una validación sintáctica. Se utilizó la librería *rapidfuzz* para realizar el cálculo de las penalizaciones y trasposición de forma óptima.

4.1.4. Bloqueo semántico: Bi-Encoder y FAISS

A pesar de las optimizaciones matemáticas con TF-IDF, el bloqueo utilizado en apartados previos carecen de comprensión semántica. Estos métodos tradicionales evalúan cada palabra de forma aislada, ignorando el contexto que les rodea, una barrera que es superada mediante arquitecturas Transformer.

A diferencia de los modelos anteriores, modelos como BERT (*Bidirectional Encoder Representations from Transformers*) o DistilBERT (su versión reducida) utilizan un mecanismo de auto-atención que analizan la frase completa para entender el contexto exacto de cada token. Esto permite que el algoritmo comprenda palabras con varios significados y asocie semánticamente términos distintos. Para aplicar esta capacidad a gran escala en RIAD, se ha optado por la arquitectura de Bi-Encoder complementada con la librería de búsqueda FAISS.

La arquitectura del Bi-Encoder se basa en procesar cada entidad de manera independiente y aislada, produciendo un vector denso continuo que resume todo su significado. Esta independencia es la clave de su escalabilidad, pues los registros de RIAD pueden vectorizarse de forma asíncrona y almacenarse en una base de datos vectorial. De este modo, ante una nueva consulta, el sistema solo necesita producir su vector y compararlo aritméticamente con la base de datos ya vectorizada, evitando el coste de procesar el par completo en tiempo real.

Para la implementación técnica se ha dividido el conjunto de registros según el país de jurisdicción y se ha utilizado el modelo multilingüe de alto rendimiento *paraphrase-multilingual-mpnet-base-v2*, el cual permite capturar equivalencias semánticas incluso en traducciones en distintos idiomas. La búsqueda de similitud se delega a la librería FAISS (*Facebook AI Similarity Search*) en Python, utilizando estrategias distintas según el volumen de datos:

- Jurisdicciones con menos de 20.000 registros: se construye un índice plano y se realiza una búsqueda exhaustiva para garantizar un alto *recall*. Al aplicar una normalización

previa de los vectores, el cálculo del producto interno por hardware se vuelve algebraicamente equivalente a la similitud coseno.

- Jurisdicciones con más de 20.000 registros: comparar cada entidad por fuerza bruta es computacionalmente inviable. Es por ello que se implementa una indexación de archivos invertidos. Este algoritmo particiona el espacio hiperdimensional en múltiples clústeres denominados células de Voronoi utilizando algoritmos no supervisados como K-Means. En la fase de búsqueda, se manipula un hiperparámetro de prospección (fijado en 10 en la experimentación) que permite investigar exclusivamente los 10 clústeres más cercanos a la consulta, manteniendo un umbral de similitud mínimo. Aunque en la práctica esto introduce un ligero compromiso entre precisión y exhaustividad, el resultado permite realizar búsquedas a gran escala de forma más rápida.

Sin embargo, en los Bi-Encoder los tokens de una entidad no interactúan con los de la otra a través de las capas de atención, lo que puede provocar que contradicciones en formas legales pasen desapercibidas. Por esta razón, la evaluación de las parejas candidatas se delega en un modelo más complejo.

4.2. Matching

Una vez los registros han sido filtrados y se dispone de un subconjunto de parejas candidatas, el objetivo es determinar con la máxima precisión posible si un par representa la misma entidad real. Para ello, se diseña un sistema de decisión que capture el contexto de ambas secuencias basado en Cross-Encoders.

En la arquitectura Cross-Encoder, las entidades a comparar se concatenan en una única secuencia antes de introducirse en el Transformer. A lo largo de las capas ocultas de la red, los mecanismos de autoatención permiten que cada elemento del primer registro interactúe bidireccionalmente con todos los elementos del segundo. Como resultado, el modelo genera una probabilidad de coincidencia a partir del vector denso asociado al token final.

En concreto, para este estudio la arquitectura implementada se ha basado en el framework DITTO (Deep Entity Matching with Pre-Trained Language Models) [19]. DITTO es un sistema de emparejamiento de entidades basado en la arquitectura de Cross-Encoder y que aprovecha

el conocimiento de modelos de lenguaje preentrenados de tipo Transformer como BERT o RoBERTa [21]. Ha demostrado tener un rendimiento mejor que los métodos de resolución de entidades basados en redes neuronales recurrentes o heurísticas estáticas. A diferencia de otros modelos relacionales clásicos que requieren una comparación atributo a atributo, DITTO permite que los registros de RIAD se serialicen en una sola cadena de texto para procesar sin problema listas de identificadores, valores faltantes y atributos desalineados. Para ello, se inyectan tokens especiales que describen la estructura semántica de los datos, emulando un contexto comprensible para el modelo de lenguaje.

- [COL] Define el nombre del atributo (ej. nombre, ciudad, dirección).
- [VAL]: Precede al valor contenido en dicha columna.
- [SEP]: Delimitador entre la Entidad 1 y la Entidad 2 dentro de la misma secuencia.

Un ejemplo de la secuencia de entrada para el modelo sería:

```
[CLS] [COL] name [VAL] Banco Santander [COL] cty [VAL] Madrid [SEP]
[COL] name [VAL] Santander Bank [COL] cty [VAL] Madrid [SEP]
[CLS] [COL] name [VAL] Banco Santander [COL] identifiers [VAL] LEI 4593...
[SEP] [COL] name [VAL] Banca Santander...
[SEP]
```

El modelo se entrenó utilizando *distilbert-base-cased* como arquitectura base del Cross-Encoder, debido a su eficacia en tareas de comprensión de lenguaje natural.

4.3. Refinamiento mediante Grafos Topológicos

Si bien el uso de modelos basados en Cross-Encoders optimiza la comparación entre pares de registros, esta evaluación plantea un nuevo desafío estructural cuando se escala el problema. En bases de datos multiorigen como RIAD, el objetivo final consiste en consolidar todos aquellos registros que representan a una misma entidad del mundo real dentro de un grupo unificado, un problema conocido en la literatura como *Entity Group Matching* [20].

La generación de estos grupos se basa en la propiedad matemática de la transitividad, es decir, si el modelo establece que un registro A coincide con un registro B , y que B coincide con C , el sistema infiere una equivalencia directa entre A y C . Bajo esta premisa, todos los registros conectados mediante relaciones transitivas conforman un único clúster o grupo. Sin embargo, la dependencia de esta propiedad provoca que si el modelo genera un falso positivo en la evaluación par a par, el error se propaga por toda la estructura topológica del grafo. Un solo enlace incorrecto puede provocar la fusión indebida de dos grupos de entidades independientes.

Para abordar el problema de la transitividad y detectar los falsos positivos dados por el modelo de predicción, este estudio incorpora una metodología topológica de validación estructural basada en el framework GraLMATCH [20]. El proceso modela las predicciones par a par sobre una estructura de red. Formalmente, se construye un grafo no dirigido $G = (V, E)$, donde los registros representan los vértices (V) y las predicciones afirmativas del modelo establecen las aristas (E). En este grafo, los grupos de entidades finales se definen matemáticamente como las componentes conexas resultantes. Para finalizar, se emplea un algoritmo de depuración de grafos, donde se analiza la topología de los subgrafos sobredimensionados para detectar y eliminar las aristas que representan falsos positivos. Se considera un grafo sobredimensionado aquel que tenga un número de nodos mayor que una constante μ , que en la literatura representa el número de fuentes distintas de donde se obtiene cada registro. Se aplican las dos siguientes técnicas:

- **Corte Mínimo de Aristas:** dado un grafo conexo $G = (V, E)$, un corte mínimo de aristas se define como un subconjunto de aristas $S \subseteq E$ de cardinalidad mínima $|S|$ cuya eliminación desconecta el grafo en dos o más componentes independientes. Esta técnica se aplica en una primera fase para fragmentar subgrafos masivos cuyo tamaño excede un umbral superior $\gamma > \mu$.
- **Centralidad de Intermediación de Aristas:** dado un grafo $G = (V, E)$, la centralidad de intermediación de una arista $e \in E$ es la suma de la fracción de todos los caminos más cortos entre pares de nodos que pasan a través de e :

$$c_B(e) = \sum_{s,t \in V} \frac{\sigma(s, t \mid e)}{\sigma(s, t)}$$




Figura 7: Evolución de los Grafos Generados: propagación de errores y depuración.

Donde $\sigma(s, t)$ es el número total de caminos más cortos entre los nodos s y t , y $\sigma(s, t | e)$ es la fracción de dichos caminos que pasan a través de la arista e . Esta técnica se aplica iterativamente en una segunda fase para intentar podar individualmente los falsos positivos en los subgrafos de tamaño superior a μ .

Cabe destacar que la eliminación de las aristas de una componente conexa utilizando el corte mínimo de aristas garantiza la desconexión de dicha componente; sin embargo, esto no ocurre necesariamente al eliminar las aristas con la mayor centralidad de intermediación. De esta manera se logra minimizar la pérdida de verdaderos positivos. En la Figura 7 se muestra un ejemplo de aplicación de ambas técnicas en subgrafos erróneamente conectados. Ambas metodologías comparten una complejidad temporal en el peor de los casos de $O(mn)$, donde n representa el número de registros y m el número de aristas del componente conexo analizado. Como salida de este proceso iterativo se consigue una red depurada de predicciones falsas con un sistema consolidado de componentes conexas.

4.4. Evaluación de los resultados

Esta sección se corresponde con la sexta fase de la metodología CRISP-DM.

El rendimiento de los algoritmos se midió principalmente a través de dos métricas: la Completitud de Pares, que indica la proporción de duplicados reales que el algoritmo es capaz de retener; y la Tasa de Reducción, que cuantifica la disminución del espacio de búsqueda respecto a la evaluación exhaustiva de todas las permutaciones posibles dentro de un mismo




Figura 8: Optimización de hiperparámetros para las estrategias de *blocking*.

país, ambas definidas en la Sección 2.

Para comparar cada técnica de *blocking*, se estableció como referencia el conjunto de verdad presentado en la Sección 3 compuesto por 116,749 pares candidatos, de los cuales un 12,85 % son verdaderos positivos. Para realizar un análisis más detallado del rendimiento de cada modelo ante distintos grados de complejidad, este subconjunto de duplicados reales se dividió en dos categorías: 7,539 coincidencias exactas (entidades que comparten el mismo nombre) y 7,472 casos complejos (pares con variaciones léxicas, acrónimos o diferencias semánticas). Cabe destacar que compartir el mismo nombre no garantiza una duplicidad real.

Se llevó a cabo una evaluación exhaustiva de hiperparámetros, analizando el comportamiento de las distintas técnicas de filtrado bajo diversas configuraciones de tolerancia. En concreto, se varió el número máximo de vecinos permitidos (k) y los umbrales de similitud requeridos. En la Figura 8 se muestra la dispersión de estos resultados enfrentando la Tasa de Reducción contra la Completitud de Pares.

Tras evaluar diversas combinaciones de tolerancia y volumen de salida, se fijó un límite máximo de 10 candidatos por registro. Los umbrales de similitud se ajustaron individualmente según la naturaleza de cada modelo:

- Filtrado léxico (TF-IDF): se estableció un umbral de similitud del 80 % para compensar

la alta dispersión de las matrices generadas.

- Filtrado Híbrido (DistilBERT + Jaro-Winkler): dada su arquitectura en dos etapas, se aplicó un filtro inicial muy permisivo de 40 % para la similitud coseno, delegando la criba final a la distancia de Jaro-Winkler con un umbral del 85 %.
- Filtrado Semántico (Bi-Encoder): se observó que al trabajar con *embeddings* densos, el número de pares candidatos tendía a dispararse sin aportar un beneficio real en el *recall* frente a las metodologías híbridas. Para frenar la entrada de falsos positivos y equilibrar el espacio de búsqueda, se estableció un umbral de similitud del 70 %.

Los resultados globales de esta fase de experimentación se resumen en la siguiente tabla:

Algoritmo / Enfoque	Tiempo (s)	Candidatos Generados	Pair Completeness / Recall (%)	Recall Exacto (%)	Recall Complejo (%)	Reduction Ratio (%)
TF-IDF n-gramas caracteres	24,9	45.055	79,46	98,08	60,67	99,98
TF-IDF DistilBERT	25,7	46.399	79,94	98,14	61,58	99,98
DistilBERT + Jaro-Winkler	97,9	131.811	91,07	98,90	83,18	99,96
Bi-Encoder (FAISS Flat)	102,8	281.655	90,35	98,82	81,80	99,91
Bi-Encoder (FAISS IVF)	100,6	255.591	90,06	98,79	81,25	99,92

Cuadro 1: Resultados del *benchmark* de las distintas técnicas de *blocking*. Destaca el Filtrado Híbrido por su equilibrio óptimo entre la retención de duplicados complejos y la reducción del espacio de búsqueda.

Como se puede observar en los resultados del Cuadro 1, estos algoritmos están diseñados exclusivamente para priorizar la velocidad maximizando el *recall*. Los métodos tradicionales basados en la vectorización léxica (TF-IDF con n-gramas y tokenización sub-palabra) destacan por su alta velocidad de ejecución y una alta Tasa de Reducción, generando un número más reducido de candidatos a evaluar en la siguiente fase. Sin embargo, son incapaces de capturar relaciones contextuales penalizando su Completitud de Pares en los casos complejos, donde apenas logran identificar un 61 % de los duplicados. Por el contrario, el enfoque híbrido (DistilBERT + Jaro-Winkler) se posiciona como la técnica más equilibrada y eficiente para este conjunto de datos, superando a los modelos Bi-Encoder no solo en precisión, sino también en eficiencia de volumen al generar la mitad de candidatos.

No obstante, es necesario realizar un análisis crítico de estas métricas considerando la procedencia de los datos. Dado que el conjunto de verdad utilizado para esta comparación

proviene de evaluaciones manuales realizadas sobre pares extraídos por el sistema heredado de RIAD (basado en la métrica de Jaro-Winkler), existe un sesgo de selección inherente. Es lógicamente esperable que el Filtrado Híbrido maximice su *recall* al replicar parcialmente la lógica con la que se construyó el conjunto de evaluación. Por este motivo, el comportamiento de las arquitecturas semánticas debe interpretarse con perspectiva. Al ser capaz de comprender sinónimos y traducciones cruzadas, el Bi-Encoder tiene el potencial de descubrir nuevos duplicados en RIAD que, a diferencia del sistema original debido a su enfoque léxico, no figuran en el conjunto de verdad actual.

Paralelamente, se evaluó el rendimiento del clasificador basado en la arquitectura Cross-Encoder utilizando un modelo DistilBERT. El entrenamiento y evaluación del modelo se realizó sobre el conjunto de verdad filtrado presentado en la Sección 3, que recoge un total de 63,370 pares candidatos. Acorde a los parámetros extraídos empíricamente, se utilizó la siguiente configuración de parámetros:

- Función de Pérdida: *Cross-Entropy Loss* para clasificación binaria, con un peso a la clase positiva de 2,5 para reducir el desbalanceo natural de clases del conjunto de datos y penalizar falsos negativos.
- Optimizador: *AdamW* con una tasa de aprendizaje de $2 \cdot 10^{-5}$ y un decaimiento de peso de 0,01. Además, se configuraron 200 pasos de calentamiento para estabilizar las primeras fases del entrenamiento.
- Tamaño de Lote (*Batch Size*): 16 pares por iteración.
- Tokenización: Se estableció una longitud máxima de secuencia de 256 *tokens*.
- Épocas: Se configuraron un máximo de 5 épocas de entrenamiento, utilizando un mecanismo de validación cruzada y añadiendo un mecanismo de parada temprana basado en la pérdida del conjunto de validación para evitar el sobreajuste.

El modelo necesitó 40 minutos en su fase de entrenamiento. Los resultados obtenidos como salida de este modelo se encuentran en el Cuadro 2. Estas evaluaciones son realizadas par a par utilizando el conjunto de test generado. Sin embargo, el objetivo final de este estudio

consiste en agrupar todos los registros correspondientes a una misma entidad real. Para ello, se utiliza la propiedad de la transitividad sobre las predicciones del modelo para construir subgrafos. Si bien este enfoque es necesario, conlleva el riesgo de propagar un único emparejamiento erróneo y fusionar indebidamente conjuntos de distintas entidades corporativas en grafos sobredimensionados. A pesar de que en RIAD el número de fuentes de datos integradas es elevado dada su naturaleza colaborativa, en este estudio el umbral de tolerancia para considerar un componente como anómalo o sobredimensionado se estableció en $\mu = 5$, al estimarse como el número máximo razonable de duplicados esperados para una misma entidad. Dado que estas predicciones falsas positivas suelen ser los únicos enlaces entre distintos clústeres, las anomalías se resolvieron dividiendo los grafos sobredimensionados ($\mu > 5$) mediante técnicas de corte mínimo de aristas con $\gamma = 15$ y centralidad de intermediación de aristas.

Se complementó la evaluación de la precisión, exhaustividad (*recall*) y F_1 tradicionales introduciendo una métrica denominada Pureza del Clúster (ClPur). Dado un emparejamiento de grupos de entidades M compuesto por subgrafos completos $\{c_i = (V_i, E_i)\}_{i=1}^N$, su pureza se formaliza mediante la siguiente ecuación:

$$\text{ClPur} = \frac{1}{\sum_{i=1}^N |V_i|} \sum_{i=1}^N |V_i| \frac{c_{TP,i}}{|E_i|}$$

Donde $c_{TP,i}$ representa el número de emparejamientos verdaderos positivos dentro del subgrafo c_i . Esta métrica determina el promedio de aciertos por grupo de registros, ponderado por el tamaño de cada clúster con el objetivo de aumentar la fiabilidad de los datos y evitar duplicados erróneos.

	Precisión (%)	Recall (%)	Valor F_1 (%)	Pureza del Clúster (ClPur)	Número de Subgrafos
Inferencia Par a Par (<i>Cross-Encoder</i>)	90.62	91.10	90.86	–	–
Pre-Depuración (Modelo + Transitividad)	92.98	94.63	93.81	0.9215	49973
Post-Depuración (Grafo depurado)	93.15	94.57	93.85	0.9223	49975

Cuadro 2: Métricas de rendimiento del Cross-Encoder frente a las etapas de agrupación transitiva y depuración de grafos en el conjunto de datos RIAD.

Se observa cómo la etapa de post-depuración incrementa la precisión y la pureza del clúster al fragmentar componentes conexos anómalos, aunque esto implique sacrificar marginal-

mente la detección de algunos verdaderos positivos. Por otro lado, es esperable encontrar un incremento del *recall* al añadir las relaciones transitivas. De este modo, se logran recuperar emparejamientos válidos que no habían sido detectados durante la fase de filtrado inicial.

Es importante destacar que no se incluye una comparativa de métricas de clasificación frente al sistema heredado, ya que no emite una predicción binaria, sino que calcula un coeficiente de similitud y delega la decisión final a la validación manual de los analistas. La ventaja cualitativa de la nueva arquitectura es precisamente su capacidad para automatizar esta clasificación final.

5

Conclusiones y Líneas Futuras

5.1. Conclusiones

La implementación de técnicas de aprendizaje profundo y estructuras de grafos ha demostrado ser una herramienta extremadamente útil para resolver el problema de la Resolución de Entidades en bases de datos a gran escala, como es el caso de RIAD en el Banco Central Europeo. Los resultados obtenidos confirman que la aplicación de modelos de procesamiento del lenguaje natural permite capturar variaciones corporativas complejas, acrónimos y ambigüedades de dominio con una fiabilidad superior a las técnicas tradicionales. Esta optimización en la detección de duplicados reduce la necesidad de una costosa verificación manual por parte de los analistas.

Con la aplicación de distintas técnicas de *blocking* se consiguió superar la complejidad combinatoria $\mathcal{O}(n^2)$ validando su viabilidad y escalabilidad en grandes conjuntos de datos. Las arquitecturas híbridas y neuronales lograron aislar eficientemente a los candidatos potenciales, alcanzando una Completitud de Pares del 90 % en el conjunto de verdad. Posteriormente, en la etapa de emparejamiento final, el clasificador neuronal superó el rendimiento de los enfoques analíticos tradicionales. Sin embargo, el éxito global de la arquitectura se encuentra en la capacidad de refinar estas predicciones mediante algoritmos de teoría de grafos. Al identificar y eliminar de forma automatizada los emparejamientos potencialmente erróneos con las técnicas presentadas, el sistema asegura la máxima pureza de los clústeres resultantes, garantizando la integridad de los datos de referencia.

Desde una perspectiva tanto personal como profesional, el desarrollo de este Trabajo de Fin de Máster ha supuesto un reto técnico y analítico al afrontar un problema real de máxima

sensibilidad, como es la calidad de los datos financieros en el Banco Central Europeo para las tareas de supervisión y estabilidad financiera del Eurosistema. El proceso de investigar y experimentar con diferentes algoritmos, además de llevar la solución a un entorno de producción, permite desarrollar habilidades en la resolución de problemas y la toma de decisiones basadas en datos, reforzando así el interés en el campo de la ciencia de datos.

5.2. Líneas Futuras

A pesar de los buenos resultados alcanzados por la arquitectura propuesta, la Resolución de Entidades en entornos como RIAD presenta otros desafíos que abren otras vías de investigación y desarrollo futuro.

El Banco Central Europeo opera bajo un estricto marco normativo que define claramente qué atributos son determinantes y cuáles presentan mayor variabilidad a la hora de identificar entidades corporativas. Para que un modelo genérico de Procesamiento de Lenguaje Natural consiga la precisión necesaria en este dominio específico, existen técnicas de integración de este conocimiento en el flujo de procesamiento. Por un lado, sería una buena propuesta realizar una inyección de conocimiento del dominio incluyendo una normalización del texto mediante un diccionario de estandarización para sufijos legales y formas jurídicas internacionales. Variantes como “Limited”, “Ltd.” o “L.t.d.” se deben agrupar de una forma unívoca antes de la tokenización, evitando así que el modelo desperdicie recursos penalizando discrepancias que no representan una diferencia real en la identidad de la empresa. De este modo, se construyen representaciones vectoriales (*embeddings*) equivalentes, lo que facilita al clasificador la detección equivalencias semánticas en ambas cadenas.

Por otro lado, conviene implementar la tipificación de atributos mediante el uso de expresiones regulares y módulos de Reconocimiento de Entidades Nombradas (NER). Se deberían inyectar etiquetas de anclaje en la fase de tokenización para campos determinantes como los identificadores (códigos LEI o identificadores fiscales nacionales). Dado que la evaluación se realiza sobre el valor del texto y no sobre la estructura de la base de datos, esta técnica es útil para resolver problemas de desalineación de esquemas, donde un identificador es registrado en otro campo por error humano. Estos *tokens* añadidos actúan como señales de alta intensidad en las capas de autoatención, permitiendo que el modelo aprenda de forma explícita que una

coincidencia en un identificador numérico es legalmente más vinculante que una coincidencia parcial en el nombre.

Además, en este estudio se acotó el espacio de búsqueda experimental al subconjunto de contrapartes de territorios extracomunitarios, donde la documentación y la denominación de las unidades organizativas se encuentran predominantemente en idioma inglés, justificando el uso computacionalmente eficiente de *DistilBERT*. Sin embargo, la extensión de esta herramienta para dar cobertura a los 16 millones de entidades del repositorio RIAD requiere abordar la diversidad lingüística del Sistema Europeo de Bancos Centrales. En este contexto, una línea futura prioritaria consiste en migrar la arquitectura base hacia modelos multilingües como *XLM-RoBERTa* o *mBERT* [22]. De esta manera se reduciría el número de casos de términos fuera de vocabulario y permitiría al *Cross-Encoder* procesar y emparejar de forma nativa registros con denominaciones en otros idiomas, con el objetivo de garantizar la equidad de las métricas de precisión y recuperación de candidatos independientemente de la jurisdicción de origen de la entidad.

Referencias

- [1] M. Romanelli, “Register of Institutions and Affiliates Database (RIAD) – Modelling for flexibility”, *Proceedings 61th ISI World Statistics Congress*, Marrakech, Sesión STS016, p. 1468, Julio 2017. Disponible en: <https://isi-web.org/sites/default/files/import//proceedings/STS016-register-of-institutions-and-affiliates-database-riad-modelling-for-flexibility.pdf>.
- [2] Q. Zhang, Z. Sun, W. Hu, M. Chen, L. Guo y Y. Qu, “Multi-view Knowledge Graph Embedding for Entity Alignment”, *Proceedings of the International Joint Conference on Artificial Intelligence (IJCAI)*, pp. 5429-5435, Ago. 2019. doi: [10.24963/ijcai.2019/754](https://doi.org/10.24963/ijcai.2019/754).
- [3] N. Barlaug y J. A. Gulla, “Neural Networks for Entity Matching: A Survey”, *ACM Transactions on Knowledge Discovery from Data*, vol. 15, no. 3, Art. no. 52, Abr. 2021. doi: [10.1145/3442200](https://doi.org/10.1145/3442200).
- [4] R. El-Ghafar, A. El-Bastawissy, E. Nasr y M. Gheith, “An Effective Entity Resolution Approach for Big Data”, *International Journal of Innovative Technology and Exploring Engineering*, vol. 10, pp. 100-112, Sep. 2021. doi: [10.35940/ijitee.K9503.09101121](https://doi.org/10.35940/ijitee.K9503.09101121).
- [5] IBM, “Conceptos básicos de ayuda de CRISP-DM - Documentación de IBM”, IBM.com. <https://www.ibm.com/docs/es/spss-modeler/saas?topic=dm-crisp-help-overview> (acceso: 16 de mayo de 2026).
- [6] E. Witt y J. Blaschke, “ECB data for analysis and decision-making: data governance and technology” en Ninth IFC Conference on “Are post-crisis statistical initiatives completed?”. Basilea, 2018. Disponible en: https://www.bis.org/ifc/publ/ifcb49_36.pdf.
- [7] Hugging Face, “Página principal de Hugging Face”, Hugging Face. <https://huggingface.co/> (acceso 16 Mayo 2026)
- [8] P. Christen, *Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection*, Berlín, Alemania: Springer Science & Business Media, 2012. doi: [10.1007/978-3-642-31164-2](https://doi.org/10.1007/978-3-642-31164-2).

- [9] V. I. Levenshtein, “Binary codes capable of correcting deletions, insertions, and reversals”, *Soviet Physics Doklady*, vol. 10, no. 8, pp. 707-710, 1966.
- [10] W. E. Winkler, “String Comparator Metrics and Enhanced Decision Rules in the Fellegi-Sunter Model of Record Linkage”, *Proceedings of the Section on Survey Research Methods, American Statistical Association*, pp. 354-359, 1990.
- [11] P. Jaccard, “Étude comparative de la distribution florale dans une portion des Alpes et des Jura”, *Bulletin de la Société Vaudoise des Sciences Naturelles*, vol. 37, pp. 547-579, 1901. doi: [10.5169/seals-266450](https://doi.org/10.5169/seals-266450).
- [12] C. D. Manning, P. Raghavan y H. Schütze, *Introduction to Information Retrieval*, Cambridge, Inglaterra: Cambridge University Press, 2008. doi: [10.1017/CBO9780511809071](https://doi.org/10.1017/CBO9780511809071).
- [13] M. Schuster y K. Nakajima, “Japanese and Korean voice search”, *2012 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 5149-5152, 2012. doi: [10.1109/ICASSP.2012.6289079](https://doi.org/10.1109/ICASSP.2012.6289079).
- [14] N. Reimers y I. Gurevych, “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, Nov. 2019. Disponible en: <https://arxiv.org/abs/1908.10084>.
- [15] J. Johnson, M. Douze y H. Jégou, “Billion-scale similarity search with GPUs”, *IEEE Transactions on Big Data*, vol. 7, no. 3, pp. 535-547, 2019. doi: [10.1109/TBDA-TA.2019.2921572](https://doi.org/10.1109/TBDA-TA.2019.2921572).
- [16] European Central Bank, “Guideline (EU) 2018/876 of the European Central Bank of 1 June 2018 on the Register of Institutions and Affiliates Data (ECB/2018/16)”, *Official Journal of the European Union*, OJ L 154, pp. 3-21, 18 de junio de 2018. Disponible en: <https://eur-lex.europa.eu/eli/guideline/2018/16/oj/eng>.
- [17] Isidro Javier García Fernández, “Implementación en Python de la Resolución de Entidades en RIAD”, *GitHub*. Disponible: <https://github.com/Isi-17/RecordLinkageRIAD> (acceso: 5 junio 2026).

- [18] V. Sanh, L. Debut, J. Chaumond y T. Wolf, “DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter”, *arXiv preprint arXiv:1910.01108*, 2019. Disponible en: <https://arxiv.org/abs/1910.01108>.
- [19] Y. Li, J. Li, Y. Suhara, A. Doan y W.-C. Tan, “Deep entity matching with pre-trained language models”, *Proceedings of the VLDB Endowment*, vol. 14, no. 1, pp. 50-60, Sep. 2020. doi: [10.14778/3421424.3421431](https://doi.org/10.14778/3421424.3421431).
- [20] F. De Meer Pardo, C. Lehmann, D. Gehrig, A. Nagy, S. Nicoli, B. Hadji Misheva, M. Brachler y K. Stockinger, “GraLMatch: Matching Groups of Entities with Graphs and Language Models”, *arXiv preprint arXiv:2406.15015*, 2024. <https://arxiv.org/abs/2406.15015>.
- [21] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer y V. Stoyanov, “RoBERTa: A Robustly Optimized BERT Pretraining Approach”, *arXiv preprint arXiv:1907.11692*, 2019. Disponible en: <https://arxiv.org/abs/1907.11692>.
- [22] A. Conneau *et al.*, “Unsupervised Cross-lingual Representation Learning at Scale”, *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pp. 8440-8451, 2020. doi: [10.18653/v1/2020.acl-main.747](https://doi.org/10.18653/v1/2020.acl-main.747).



UNIVERSIDAD
DE MÁLAGA

| **uma.es**

E.T.S. DE INGENIERÍA INFORMÁTICA

E.T.S de Ingeniería Informática
Bulevar Louis Pasteur, 35
Campus de Teatinos
29071 Málaga